

Отчёт по исследованию рекомендательной системы

На данных Netflix Prize: сравнение SVD++, кастомной матричной факторизации с учётом времени (TemporalMF) и нейросетевой коллаборативной фильтрации (NCF)

1. Данные и постановка задачи

Работа выполнена на датасете Netflix Prize: четыре файла с оценками (combined_data_1–4), файл со справочником фильмов movie_titles.csv (17 434 фильма) и метаданными. По числу уникальных фильмов и пользователей файлы сопоставимы (от 4 157 до 4 711 фильмов и от 470 758 до 475 601 пользователей на файл), однако именно во втором файле (df2) оказалось наибольшее количество отдельных оценок — около 27 млн строк (26 977 591 после разметки года). Для проведения экспериментов и сравнения алгоритмов без обучения на всём объёме данных (более 100 млн оценок суммарно) было решено использовать только df2. Работы выполнены в среде Kaggle на GPU T4X2

В справочнике фильмов у 7 записей отсутствовал год выпуска — пропуски заполнены вручную на основе фактических годов выпуска (например, «Ancient Civilizations: Rome and Pompeii» — 2001, «Roti Kapada Aur Makaan» — 1974).

Количество данных в df2 является самым большим из всех разделённых датасетов, поэтому выбор был сделан в пользу его. Количество строк в df2 составляет около 27 миллионов и содержит наибольшее количество уникальных фильмов, что делает его гораздо более информативным чем другие датасеты

Метрики оценки качества

Для сравнения моделей использовались четыре метрики. RMSE и MAE оценивают точность предсказания самой оценки (насколько предсказанный рейтинг близок к реальному). Precision@10 показывает долю действительно релевантных фильмов (с реальной оценкой ≥ 4) среди топ-10 рекомендаций, отсортированных по предсказанному рейтингу — то есть отвечает на вопрос «сколько из предложенных фильмов пользователю пригодится». NDCG@10 дополнительно учитывает порядок внутри топ-10, сравнивая ранжирование по предсказанной оценке с идеальным ранжированием по реальной оценке — отвечает на вопрос «насколько удачно расставлены по местам уже отобранные кандидаты». Отдельно фиксировалось время обучения — как практический фактор, значимый при выборе модели.

Модели TemporalMF и NCF обучались на хронологическом разбиении: все оценки df2 были отсортированы по дате, первые 80% (более ранние по времени) вошли в обучающую выборку, последние 20% (более поздние) — в тестовую. Такое разбиение честнее случайного, поскольку не допускает ситуации, когда модель училась на оценках из «будущего» относительно тестовых объектов, но одновременно усложняет задачу — часть пользователей и фильмов из теста может быть слабо представлена в обучающей выборке.

2. Гипотезы и результаты экспериментов

Гипотеза 1. Базовая модель SVD++ без учёта времени

Предположение: Классическая факторизационная модель SVD++, работающая только с тройкой (CustomerID, MovieID, Rating), без временного фактора, даст приемлемое качество ранжирования, но не будет использовать всю доступную информацию о датасете.

Результат: На случайном разбиении (80/20) SVD++ показала RMSE = 0.936, MAE = 0.717, Precision@10 = 0.416, NDCG@10 = 0.808. Обучение заняло около 25 минут (1519 с) — заметно быстрее обеих последующих моделей.

Вывод: SVD++ хорошо ранжирует фильмы внутри списка уже отобранных кандидатов (высокий NDCG), но из каждых 10 рекомендованных фильмов лишь 4 оказываются релевантными пользователю (Precision@10 = 0.42) — модель не использует временной контекст и обучалась на случайном, а не хронологическом разбиении, что делает задачу для неё легче, чем для последующих моделей.

Гипотеза 2. Учёт временного смещения (TemporalMF)

Предположение: Добавление в матричную факторизацию временного признака — нормированной даты оценки (от 0 до 1 между минимальной и максимальной датой пользователя) и обучаемого временного смещения b_t — повысит долю релевантных рекомендаций (Precision@10) по сравнению с SVD++, за счёт учёта предпочтений во времени. Дополнительное условие эксперимента: обучение проводится на более ранних по времени оценках (первые 80% по дате), тест — на более поздних (последние 20%), а не на случайном разбиении.

Результат: Precision@10 вырос до 0.708 (против 0.416 у SVD++) — более чем в 1.7 раза. NDCG@10 остался практически на том же уровне: 0.807 против 0.808. При этом RMSE вырос до 1.014, а обучение заняло около 63 минут (3769 с) — почти в 2.5 раза дольше, чем SVD++.

Вывод: Учёт времени действительно радикально улучшает Precision@10, то есть модель существенно точнее отбирает кандидатов, которые пользователю нужны. Рост RMSE и увеличение времени обучения — ожидаемый фактор: во-первых, оценка на хронологическом разбиении честнее и сложнее для модели, чем случайное разбиение (тестовые пользователи и фильмы частично новы для модели — эффект, отсутствующий в тесте SVD++); во-вторых, обучение через мини-батчи в PyTorch на CPU/GPU медленнее

Гипотеза 3. Нейросетевая коллаборативная фильтрация (NCF)

Предположение: Замена скалярного произведения эмбедингов на комбинацию GMF (поэлементное произведение) и MLP-ветки с явной подачей временного признака на вход сети даст дополнительный прирост качества по сравнению с TemporalMF за счёт способности сети находить нелинейные взаимодействия между пользователем, фильмом и временем.

Результат: NCF показала Precision@10 = 0.710 (практически на уровне TemporalMF — 0.708), NDCG@10 = 0.811 (немного выше, чем у TemporalMF — 0.807), RMSE = 1.006 (немного ниже, чем у TemporalMF — 1.014). Обучение заняло около 75.5 минут (4530 с) — на 20% дольше, чем TemporalMF, и почти втрое дольше SVD++.

Вывод: Усложнение архитектуры дало умеренный, а не радикальный прирост качества: разница с TemporalMF по всем трём метрикам качества составляет доли процента, тогда как время обучения выросло существенно. Основной прирост качества относительно baseline был получен именно на этапе добавления временного признака (гипотеза 2), а не на этапе усложнения архитектуры модели (гипотеза 3) — это указывает на убывающую отдачу от дальнейшего усложнения модели в рамках рассмотренных архитектур.

Гипотеза 4. Похожие агрегированные метрики не означают одинаковые рекомендации

Предположение: Несмотря на близкие значения метрик, TemporalMF и NCF, обученные на одних и тех же данных, будут давать заметно различающиеся персональные рекомендации одному и тому же пользователю — то есть агрегированные метрики недостаточны для вывода об идентичности моделей на уровне конечного пользователя.

Результат: Для тестового пользователя (CustomerID = 1049643) сравнили топ-10 рекомендаций каждой модели: пересечение составило только 4 фильма из 10 — «The Lord of the Rings: The Fellowship of the Ring», «The Lord of the Rings: The Two Towers (Extended Edition)», «The Simpsons: Season 5» и «Arrested Development: Season 2» (см. таблицу ниже), причём даже у общих фильмов порядок в топ-10 отличается между моделями.

Вывод: Подтверждено: близость моделей по RMSE/Precision/NDCG не гарантирует совпадения рекомендаций на уровне отдельного пользователя. Выбор конкретной модели для продакшена — это не только вопрос агрегированных метрик, но и вопрос того, какой профиль рекомендаций (более консервативный или более разнообразный) нужен продукту.

Архитектуры рассмотренных моделей

- SVD++ (библиотека surprise) — классическая факторизационная модель: предсказание строится как сумма глобального среднего, смещений пользователя и фильма и скалярного произведения их латентных векторов, дополненная implicit-сигналом от самого факта взаимодействия пользователя с фильмами. Время не используется.
- TemporalMF (собственная реализация на PyTorch) — аналогичная по духу факторизация (эмбединги пользователя и фильма, их смещения, скалярное произведение), дополненная обучаемым линейным временным смещением b_t , зависящим от нормированной даты оценки. Обучалась 10 эпох с оптимизатором Adam, батч 8192 объекта.
- NCF (Neural Collaborative Filtering) — совмещает GMF-ветку (поэлементное произведение эмбедингов, аналог классической факторизации) и MLP-ветку (эмбединги пользователя и фильма подаются в полносвязную сеть 128,64,32 со слоями ReLU и Dropout), к выходу обеих веток добавляется нормированная дата как дополнительный вход финального слоя. Обучалась также 10 эпох, Adam, тот же размер батча.

3. Сводное сравнение моделей

Модель	RMSE	Precision@10	NDCG@10	Время обучения
SVD++ (surprise)	0.936	0.416	0.808	~25.3 мин (1519 с)
TemporalMF	1.014	0.708	0.807	~62.8 мин (3769 с)

Модель	RMSE	Precision@10	NDCG@10	Время обучения
NCF (GMF + MLP)	1.006	0.710	0.811	~75.5 мин (4530 с)

Значения RMSE и MAE для SVD++ получены на случайном 80/20-разбиении; значения для TemporalMF и NCF — на строго хронологическом разбиении (первые 80% оценок по дате — обучение, последние 20% — тест), поэтому прямое сравнение RMSE между SVD++ и двумя другими моделями не полностью корректно и приведено здесь для общей ориентировки, а не как строгое ранжирование качества.

Пересечение персональных рекомендаций (TemporalMF vs NCF)

MovieID	Название	TemporalMF, ранг	NCF, ранг
7230	The Lord of the Rings: The Fellowship of the Ring	1	2
7057	Lord of the Rings: The Two Towers (Extended Ed.)	2	5
5103	The Simpsons: Season 5	7	1
7833	Arrested Development: Season 2	10	4

Из 10 рекомендованных позиций каждой модели совпали 4 фильма — оставшиеся 6 позиций в топ-10 каждой модели уникальны и не встречаются в топ-10 второй модели.

4. Общие выводы

- Добавление временного признака в матричную факторизацию — наиболее эффективное по соотношению «эффект/сложность» улучшение среди рассмотренных: Precision@10 вырос с 0.42 до 0.71 при относительно небольшом усложнении модели по сравнению с переходом к полноценной нейросетевой архитектуре.
- Дальнейшее усложнение модели (переход от TemporalMF к NCF) даёт лишь незначительный прирост метрик качества (доли процента по Precision@10, NDCG и RMSE), но существенно увеличивает время обучения (+20% относительно TemporalMF, +3X относительно SVD++).
- SVD++ остаётся наиболее быстрым в обучении вариантом и показывает лучший результат по ранжированию уже отобранных кандидатов (сопоставимый NDCG), но заметно уступает по Precision@10 — доле действительно релевантных фильмов среди рекомендованных.
- Честное хронологическое разбиение train/test для моделей с учётом времени усложняет задачу по сравнению со случайным разбиением, что частично объясняет рост RMSE у TemporalMF и NCF относительно SVD++ — часть разницы в RMSE отражает не столько качество модели, сколько сложность самого тестового сценария.
- Практическое сравнение рекомендаций для одного пользователя показывает, что решение о выборе конкретной архитектуры должно учитывать не только сводные метрики, но и то, насколько по-разному модели формируют персональные списки — совпадение лишь 4 из 10 позиций между TemporalMF и NCF существенно для продуктовых решений.